

1 引言

混沌系统同步控制是非线性动力学与智能控制领域的重要研究主题，在保密通信、复杂网络分析和神经信息处理等方面具有重要应用价值。由于混沌系统具有对初值高度敏感、动力学行为复杂以及强非线性耦合等特征，其同步控制问题长期以来受到广泛关注。尤其是在驱动-响应框架下，如何通过有限控制输入实现主从系统的稳定同步，仍然是混沌控制研究中的一个核心问题。

Hopfield 型神经网络作为一类典型的非线性动力系统，不仅在联想记忆和优化计算中具有重要意义，而且在适当参数条件下能够呈现丰富的混沌行为。因此，围绕 Hopfield 型混沌神经网络的同步控制设计与鲁棒性分析，已成为相关研究中的一个重要方向。已有工作主要采用线性反馈、自适应控制、脉冲控制和间歇控制等方法实现混沌神经网络同步。然而，这些方法通常依赖较明确的系统模型与较理想的观测条件，当系统存在参数失配、突发扰动或观测受限时，其性能往往会受到影响。

近年来，深度强化学习（Deep Reinforcement Learning, DRL）在复杂连续控制问题中展现出较强的自学习能力和环境适应能力，为非线性系统控制提供了新的思路。与传统基于模型的控制方法相比，深度强化学习能够通过与环境交互直接学习控制策略，因此在模型不确定和信息受限场景中具有潜在优势。尽管已有研究开始尝试将强化学习用于混沌系统控制，但针对连续时间 Hopfield 型混沌神经网络，在单输入牵制控制、参数失配、全局脉冲扰动和部分可观测条件下开展系统研究的工作仍相对有限。

针对上述问题，本文研究连续时间 Hopfield 型混沌神经网络的单输入同步控制问题。首先，从局部稳定性与可控性角度分析不同牵制节点的控制特性，为 pinning 节点选择提供理论依据。随后，采用基于 PPO 的深度强化学习方法设计单输入同步控制策略，并与传统线性反馈控制进行比较。在此基础上，进一步从参数失配、全局脉冲扰动和部分可观测等多个角度考察所提方法的鲁棒性与适应性。实验结果表明，在理论最优牵制节点下，PPO 能够实现与传统方法相当的同步性能；而在非最优控制节点以及更具挑战性的观测受限场景下，所提方法表现出更强的适应能力。

本文的主要贡献如下：

1. 针对连续时间 Hopfield 型混沌神经网络，构建驱动-响应同步误差系统，并结合局部稳定性与可控性分析给出单输入牵制节点选择依据。

2. 设计基于 PPO 的单输入同步控制策略，并在参数失配和全局脉冲扰动场景下与传统线性反馈控制进行比较。
3. 研究观测受限条件下的同步性能，分析不同观测维度和不同牵制节点对策略可学习性的影响。

2 预备知识与系统模型

2.1 连续 Hopfield 神经网络动力学

Hopfield 于 1984 年提出的连续神经网络模型 [1] 可表示为：

$$C_i \frac{du_i}{dt} = \sum_{j=1}^n T_{ij} V_j - \frac{u_i}{R_i} + I_i, \quad (1)$$

并满足输入输出静态非线性映射 $V_i = g_i(u_i)$ 。其中， u_i 为神经元的内部状态变量， V_i 为神经元输出， C_i 和 R_i 分别表示等效电容和电阻， T_{ij} 表示突触连接权重， I_i 为外部偏置输入。

Hopfield 在其原始研究中将 T 设定为对称矩阵，以在数学上保证系统能量函数的单调递减性，但这会导致网络最终收敛于静态平衡点，无法产生混沌行为。为了专注于神经网络内部复杂拓扑耦合所引发的非线性分岔与混沌吸引子特性，控制理论领域通常对原始方程进行无量纲化处理 [2, 3]。

引入参数代换 $a_i = \frac{1}{R_i C_i}$, $w_{ij} = \frac{T_{ij}}{C_i}$, $b_i = \frac{I_i}{C_i}$ 。假设各神经元具有相同的泄漏系数 ($a_i = 1$)，忽略常值偏置 ($\mathbf{b} = \mathbf{0}$)，并选取 $\tanh(\cdot)$ 刻画神经元输出的饱和非线性，可得到广泛用于非线性动力学研究的连续时间 Hopfield 型神经网络一般形式：

$$\dot{\mathbf{x}}(t) = -\mathbf{x}(t) + W \tanh(\mathbf{x}(t)), \quad (2)$$

其中， $\mathbf{x}(t) = [x_1(t), x_2(t), x_3(t)]^T$ 为三节点驱动系统的状态向量。本文设定网络权重矩阵为：

$$W = \begin{bmatrix} -1.4 & 1.2 & -7.0 \\ 1.1 & 0.0 & 2.8 \\ 0.8 & -2.0 & 4.0 \end{bmatrix}. \quad (3)$$

在初始条件 $\mathbf{x}(0) = [0, 0.01, 0]^T$ 下，通过经典的四阶龙格-库塔 (RK4) 算法对式 (2) 进行数值积分，系统展现出极度复杂的双涡卷混沌吸引子 (如 Fig. 1 和 Fig. 2 所示)，这证明了该系统具有强烈的内禀不稳定性。




图 1: 连续时间 Hopfield 型混沌神经网络的时域演化轨迹




图 2: 连续时间 Hopfield 型混沌神经网络的相平面轨迹

2.2 牵制同步控制问题描述

为了实现混沌驱动系统与响应系统的渐近同步，我们在响应系统中引入单变量牵制控制（Single-variable Pinning Control），其动力学方程一般化地表示为：

$$\dot{\mathbf{y}}(t) = -\mathbf{y}(t) + W_r \tanh(\mathbf{y}(t)) + Bu(t), \quad (4)$$

其中， $\mathbf{y}(t) \in \mathbb{R}^3$ 为响应系统状态； W_r 为响应系统权重矩阵（允许与 W 存在微小硬件参数失配）； $u(t) \in \mathbb{R}$ 为标量控制输入； $B \in \mathbb{R}^{3 \times 1}$ 为牵制节点选择向量，用于决定控制信号注入的具体物理节点，三个分量中只有 1 个为 1，其余为 0。

定义同步误差系统为 $\mathbf{e}(t) = \mathbf{y}(t) - \mathbf{x}(t)$ ，则主从同步问题可转化为误差系统的渐近稳定性问题 [4]，可得误差动力学演化方程：

$$\dot{\mathbf{e}}(t) = -\mathbf{e}(t) + W_r \tanh(\mathbf{y}(t)) - W \tanh(\mathbf{x}(t)) + Bu(t). \quad (5)$$

Definition 1. 对于驱动系统 (2) 和带有牵制控制的响应系统 (4)，若在控制律 $u(t)$ 的作用下，满足 $\lim_{t \rightarrow \infty} \|\mathbf{e}(t)\| = 0$ ，则称系统实现了渐近同步。

3 基于深度强化学习的牵制控制策略

求解非线性欠驱动误差系统 (5) 的最优控制律 $u(t)$ 是一项极具挑战性的任务。传统的解析控制方法往往严重依赖精确的数学模型。为此，本文提出一种数据驱动的 DRL 控制框架。在应用 DRL 进行策略搜索前，必须首先确定控制节点，状态建模和算法选择。

3.1 不同牵制节点下的局部稳定性与可控性综合分析

为了从理论层面解释不同单输入牵制节点下同步性能的差异，本文在同步流形附近对误差系统进行局部分析，并从局部稳定性、最优控制代价以及控制传播能力三个角度，对节点 1、节点 2 和节点 3 的局部可控性进行综合比较。

当同步误差趋于零，即 $e \rightarrow 0$ 时，取 $W_r \approx W$ ，并对非线性项作一阶展开，可得到误差系统近似线性化形式 [5]。

$$\dot{\mathbf{e}}(t) \approx [-I + WD(x(t))] \mathbf{e}(t) + Bu(t), \quad (6)$$

其中, I 表示 3×3 单位矩阵, W 为驱动系统的权重矩阵, $u(t) \in \mathbb{R}$ 为单输入控制量, $B \in \mathbb{R}^{3 \times 1}$ 为控制分配向量, 决定控制作用于哪个节点; $D(x)$ 为由激活函数导数构成的对角矩阵:

$$D(x) = \text{diag}(1 - \tanh^2(x_1), 1 - \tanh^2(x_2), 1 - \tanh^2(x_3)), \quad (7)$$

其中 x_1, x_2, x_3 为驱动系统状态变量。

对于单输入牵制控制, 不同节点选择对应不同的控制分配向量:

$$B_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad B_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad B_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \quad (8)$$

其中, B_1 、 B_2 、 B_3 分别表示控制输入施加于节点 1、节点 2 和节点 3。

首先, 采用最大条件李雅普诺夫指数 (Maximum Conditional Lyapunov Exponent, MCLE) [6] 刻画同步流形附近小扰动的渐近演化趋势。其定义为

$$\lambda_{\max}^{(c)}(B_i) = \lim_{t \rightarrow \infty} \frac{1}{t} \ln \frac{\|\delta e_i(t)\|}{\|\delta e_i(0)\|}, \quad (9)$$

其中, $\delta e_i(t)$ 表示在第 i 个牵制节点对应控制通道下, 误差系统横向无穷小扰动的演化轨迹, $\|\cdot\|$ 表示向量范数。若 $\lambda_{\max}^{(c)}(B_i) < 0$, 则说明同步流形局部稳定; 若 $\lambda_{\max}^{(c)}(B_i) > 0$, 则说明同步流形局部不稳定。

其次, 为比较不同节点下的局部最优控制难度, 在局部线性化模型基础上引入 LQR 二次型性能指标 [7]

$$J = \int_0^\infty (e^T Q e + u^T R u) dt, \quad (10)$$

其中, J 表示最优控制代价, Q 为误差状态加权矩阵, R 为控制输入加权矩阵。该指标用于综合衡量误差收敛质量与控制输入代价。对应的最优状态反馈控制律写为

$$u = -K e, \quad (11)$$

其中, K 为最优反馈增益矩阵, 其表达式为

$$K = R^{-1} B^T P, \quad (12)$$

矩阵 P 由对应的 Riccati 方程确定。本文进一步使用 $\|K\|$ 表示反馈增益的范数, 用于度量控制律的激进程度。

最后，为衡量控制作用通过不同节点向整个误差子空间传播的能力，基于有限时间可控性 Gramian 的思想 [8] 构造可控性矩阵。

为了给出更直观的节点排序指标，本文进一步在零点处对系统进行局部线性化。由于在 $x = 0$ 处有 $\tanh(0) = 0$ 且 $D(0) = I$ ，因此局部线性化矩阵退化为

$$A = W - I. \quad (13)$$

在此基础上构造可控性矩阵

$$C_i = [B_i, AB_i, A^2B_i], \quad i = 1, 2, 3, \quad (14)$$

并定义局部控制体积指标为

$$\mathcal{V}_i = \det(C_i)^2 \quad (15)$$

其中， C_i 用于描述控制输入通过第 i 个节点向整个局部状态空间传播的能力， $\mathcal{V}_i$ 越大，说明该节点的控制传播能力越强。

表 1: 不同牵制节点下的局部稳定性与可控性指标比较

Pinning Node	MCLE $\lambda_{\max}^{(c)}(B)$	LQR Cost J	Gain Norm $\ K\ $	Control Volume Index
Node 1	+0.6061	280.2686	20.3937	0.479
Node 2	+1.5793	15.5170	6.7286	262.18
Node 3	-0.5853	7.8327	4.3829	290.77

由表 1 可见，不同牵制节点在当前连续时间 Hopfield 型混沌神经网络中表现出显著不同的局部控制特性。节点 3 的 MCLE 为负，说明同步流形在该节点控制下局部稳定；同时，其最优控制代价最低、反馈增益范数最小且控制体积指标最大，表明节点 3 在局部稳定性、控制难度和控制传播能力三个层面均占优，因此是当前系统中最优的单输入牵制节点。

相比之下，节点 2 虽然具有较大的控制体积指标和中等水平的最优控制代价，说明其控制作用在局部状态空间中仍具有较强传播能力，但由于其 MCLE 为正，同步流形在该控制通道下局部不稳定，因此基于局部线性反馈结构的传统控制方法在节点 2 上存在失效风险。节点 1 的情况则更为明显，其 MCLE 为正，且最优控制代价与反馈增益范数均远高于其余两个节点，同时控制体积指标极小，说明该节点在局部控制传播能力与控制效率两个方面都最弱。

综合上述理论指标,可以得到如下排序关系:

$$\text{Node 3} > \text{Node 2} \gg \text{Node 1} \quad (16)$$

其中,节点 3 在局部稳定性、最优控制代价和控制传播能力三个方面均最优;节点 2 具有一定局部可控性,但传统线性控制难以保证其可靠同步;节点 1 则在多个指标上均表现最差。该综合分析为后续深度强化学习控制策略的节点选择提供了理论依据。

需要说明的是,上述分析建立在同步流形附近的局部线性化误差系统基础上,因此其主要刻画的是小误差区域内的局部稳定性和可控性特征。对于深度强化学习而言,其闭环训练过程属于有限时间、全局非线性和策略参数化条件下的控制问题,因此局部理论判据与最终训练表现之间可能存在一定差异。然而,MCLE、LQR 代价以及控制体积指标在节点优劣排序上的一致性,仍然为不同牵制节点的比较提供了重要的理论支撑。

3.2 马尔可夫决策过程建模

在确定牵制靶点后,本文将驱动-响应系统同步过程建模为连续状态、连续动作的马尔可夫决策过程(Markov Decision Process, MDP)。

1) **观测空间**为使智能体同时感知驱动系统的即时动力学状态与当前同步偏差,定义观测向量为

$$O_t = \frac{1}{\sigma} [x_1(t), x_2(t), x_3(t), e_1(t), e_2(t), e_3(t)]^T, \quad (17)$$

其中 $\sigma = 5.0$ 为归一化因子,用于抑制极端状态值对神经网络训练稳定性的影响。

2) **动作空间与物理推力映射**策略网络输出原始动作 a_t , 其取值被约束于连续区间 $[-1, 1]$ 。考虑执行器能力限制,将其映射为作用于响应系统第 3 节点的真实控制输入:

$$u(t) = \kappa a_t, \quad (18)$$

其中 κ 为控制增益,本文取 $\kappa = 4$ 。

3) **奖励函数**本文当前阶段主要关注同步误差的快速收敛能力,因此奖励函数直接由全局同步误差构造:

$$r_t = -\|e(t)\|_1 = -\sum_{i=1}^3 |e_i(t)|. \quad (19)$$

该奖励函数具有明确的物理意义，即同步误差越小，奖励越高；同时避免了引入过多手工塑形项，有利于突出策略学习对同步目标本身的响应。关于控制能耗与同步性能之间的折中问题，将在后续工作中进一步讨论。

3.3 基于 PPO 算法的策略优化

为求解上述连续动作空间下的最优控制策略，本文采用近端策略优化 (Proximal Policy Optimization, PPO) 算法 [9]。PPO 属于典型的 Actor-Critic 类方法，其通过裁剪机制限制策略更新幅度，在保证训练稳定性的同时兼顾较高的采样效率。

PPO 的目标函数写为

$$L(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (20)$$

其中

$$\rho_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)} \quad (21)$$

表示新旧策略的概率比， ϵ 为裁剪超参数， $\hat{A}_t$ 为广义优势估计 (GAE) 得到的优势函数。通过与连续时间 Hopfield 型混沌系统进行交互，PPO 能够逐步学习在单输入牵制控制约束下最小化长期同步误差的非线性控制策略。




图 3: 基于 PPO 的单输入牵制控制框架示意图

4 实验结果与分析

本节从牵制节点选择、系统同步参数失配鲁棒性 [10] 以及脉冲扰动恢复能力三个方面，对所提出的深度强化学习牵制控制方法进行实验分析。

4.1 实验设置

本章详细介绍了在配备 RTX 5070Ti 显卡的计算机上进行的实验。所有程序均使用 Python 编写，PPO 算法采用 Stable Baselines3 实现。训练过程持续 40 万个时间步。微分方程求解过程中，每个时间步长为 0.01 个单位。最大控制力为 4 个单位。在系统初始化阶段，本研究并未采用宽泛的随机边界，而是将驱动系统与响应系统的初始状态 $x(0)$ 和 $y(0)$ 均从均匀分布 $[-1.0, 1.0]$ 中进行采样。这一设计的物理考量在于：该区间覆盖了 $\tanh(\cdot)$ 激活函数的强非线性区域（即非饱和区）。将初始状态锚定于此，能够确保智能体在探索初期即面临剧烈的混沌动力学演化，避免了因状态过度饱和导致的无效计算。在强化学习算法配置方面，策略网络与价值网络均采用多层感知器（MLP）架构进行拟合。为了在探索的高效性与策略更新的稳定性之间取得平衡，优化器（Adam）的学习率被设定为 3×10^{-4} 。作为传统控制基线，本文采用固定增益线性反馈 [11] 控制律

$$u(t) = -k e_i(t), \quad (22)$$

其中， i 表示受控节点标号， $e_i(t)$ 表示受控节点的同步误差， k 为反馈增益。考虑到本文研究重点并非线性反馈参数的最优整定，而是将其作为一个结构简单、易于实现的传统控制基线与所提深度强化学习方法进行比较，因此 k 通过预实验经验调节确定。综合标称工况下的稳定性与收敛速度，本文取 $k = 8.0$ 作为线性反馈控制的固定增益参数。

为全面评估不同控制方法在连续时间 Hopfield 型混沌神经网络同步任务中的性能，本文从整体同步精度、稳态误差、瞬态恢复能力以及控制代价四个方面定义如下评价指标。

设测试总步数为 T ，系统状态维数为 N ，同步误差向量记为

$$e(t) = y(t) - x(t) = [e_1(t), e_2(t), \dots, e_N(t)]^T. \quad (23)$$

1) 平均绝对误差（Mean Absolute Error, MAE）用于衡量整个测试区间内的平均同步偏差，定义为

$$\text{MAE} = \frac{1}{TN} \sum_{t=1}^T \sum_{i=1}^N |e_i(t)|. \quad (24)$$

MAE 能够直观反映系统整体误差水平，对不同时间步和不同状态分量赋予相同权重。

2) 均方根误差 (**Root Mean Square Error, RMSE**) 用于刻画整体误差水平并增强对较大误差的敏感性, 定义为

$$\text{RMSE} = \sqrt{\frac{1}{TN} \sum_{t=1}^T \sum_{i=1}^N e_i^2(t)}. \quad (25)$$

与 MAE 相比, RMSE 对突发大误差更敏感, 因此更适合表征失配和脉冲扰动条件下的误差波动。

3) 终端时刻误差 (**Final L_1 Error**) 用于衡量系统最终稳态同步精度, 定义为

$$E_f = \|e(T)\|_1 = \sum_{i=1}^N |e_i(T)|. \quad (26)$$

该指标反映控制方法在测试结束时对同步目标的逼近程度。

4) 脉冲后最大误差峰值 (**Max Post-Pulse Error**) 在脉冲扰动实验中, 用于描述扰动作用后系统误差的最大超调程度, 定义为

$$M_p = \max_{t \geq t_p} \|e(t)\|_1, \quad (27)$$

其中, t_p 表示脉冲扰动注入时刻。该指标越小, 说明控制器对突发扰动的峰值抑制能力越强。

5) 脉冲后平均误差 (**Post-Pulse Mean Error**) 定义为脉冲扰动注入后至测试结束阶段全局同步误差 $\|e(t)\|_1$ 的平均值, 即

$$E_{\text{post}} = \frac{1}{T - t_p + 1} \sum_{t=t_p}^T \|e(t)\|_1, \quad (28)$$

其中 t_p 表示脉冲注入时刻, T 表示测试结束时刻。

6) 控制能量 (**Control Energy**) 用于衡量整个测试过程中的累计控制代价, 定义为

$$E_u = \sum_{t=1}^T u^2(t) \Delta t, \quad (29)$$

其中, Δt 表示采样时间步长。该指标对较大幅值控制输入更敏感, 是评价控制 effort 的常用指标。

综上, 本文采用 MAE 与 RMSE 衡量整体同步性能, 采用 Final L_1 Error 描述稳态同步精度, 采用 Max Post-Pulse Error 与 Post-Pulse Mean Error 刻画突发扰动下的瞬态恢复能力, 并使用 Control Energy 评估控制代价。

4.2 不同 pinning 节点下的同步可达性比较

为验证前述局部稳定性与可控性分析对牵制节点选择的指导作用,本文在相同训练配置下,分别将单输入控制施加于节点 1、节点 2 和节点 3,并比较不同 pinning 节点下策略训练后的同步性能。需要说明的是,该组实验的目的并非重新设计控制器结构,而是在统一控制框架下考察不同牵制节点对同步可达性的影响。相关误差演化结果如图 4 所示,定量比较结果见表 2。

由图 4 可以看出,不同牵制节点下系统的同步误差演化存在明显差异。在节点 3 作为控制节点时,误差能够更快衰减并稳定保持在较低水平,表现出最好的同步可达性;相比之下,节点 2 虽然在一定条件下也能够实现同步,但其误差收敛速度和最终误差水平通常不如节点 3 稳定;节点 1 的控制效果最弱,在相同训练设置下更难获得可靠的同步性能。

为避免仅凭单条误差曲线进行定性判断,本文进一步采用 MAE 和 Final L_1 Error 对不同 pinning 节点下的同步性能进行定量比较。表 2 的定量结果进一步验证了上述现象。无论从平均误差水平还是终端时刻误差来看,节点 3 均表现出更优的整体同步性能。这表明,在当前连续时间 Hopfield 型混沌神经网络中,节点 3 更适合作为单输入牵制控制的作用节点。该实验结果与前述基于 MCLE、LQR 代价以及控制传播能力指标的理论排序总体一致,即节点 3 的局部稳定性和可控性均优于其余节点。

为了进一步考察所选 pinning 节点对初始条件变化的适应能力,本文还在节点 3 场景下选取多组不同随机初始状态进行测试,结果如图 5 所示。可以看出,在不同初始条件下,系统误差均能够逐步收敛至较低水平,说明以节点 3 作为牵制节点时,所学控制策略不仅具有较好的同步性能,而且对初始状态扰动具有一定鲁棒性。

综合以上结果可以认为,节点 3 在当前系统中具有最优的同步可达性,因此后续参数失配与脉冲扰动等实验均基于节点 3 展开;节点 2 则作为一个非最优但仍具有一定可控性的补充场景,用于进一步考察所提方法在更具挑战性控制通道下的适应能力。

4.3 参数失配设置说明

为评估控制策略在模型不确定性条件下的鲁棒同步性能,本文在响应系统中引入权重矩阵失配,参数失配会显著影响同步质量,是检验鲁棒性的重要方式之一 [12]。设驱动系统权重矩阵为 W ,则响应系统的失配权重矩阵




图 4: 不同节点在相同环境下的控制性能

表 2: 不同节点总误差的 MAE 和 RMSE

Node	MAE	RMSE
Node 1	4.1400	4.6987
Node 2	0.2574	0.7232
Node 3	0.1061	0.3055




图 5: 节点 3 在不同初值下的鲁棒性验证

构造为

$$W_r = W + \eta (W \odot \Delta), \quad (30)$$

其中, η 表示失配强度系数, $\odot$ 表示 Hadamard 逐元素乘积, $\Delta = [\delta_{ij}]$ 为随机扰动矩阵, 其元素满足

$$\delta_{ij} \sim \mathcal{U}(-0.03, 0.03). \quad (31)$$

由式 (30) 可知, 本文采用的是一种相对乘性失配建模方式, 即响应系统中每个非零连接权重均在其标称值基础上引入随机相对偏差, 而零连接项保持不变。该建模方式具有两个优点: 其一, 它能够保留原网络拓扑结构, 不会由于参数扰动而凭空产生新的耦合连接; 其二, 相较于固定加性失配矩阵, 乘性失配更符合器件制造误差、参数标定偏差和元件容差等实际场景。

需要说明的是, 失配强度系数 η 为归一化调节参数, 而非直接表示百分比失配幅度。当 $\eta = 1.0$ 时, 对应的相对扰动范围约为原权重的 $\pm 3\%$; 当 $\eta = 2.0$ 时, 对应的相对扰动范围约为原权重的 $\pm 6\%$ 。因此, 本文通过改变 η 的取值来系统考察控制器在不同程度参数不确定性下的同步性能变化。

在训练阶段, 响应系统的失配矩阵在每次环境重置时随机生成, 从而形

成多样化的参数摄动场景。这种处理方式有助于提升所学策略对模型不确定性的适应能力。在测试阶段，本文在给定失配强度水平下对控制器进行评估，并比较不同方法在多种失配工况下的同步误差、瞬态恢复能力和控制代价。

为便于定量分析，本文选取如下失配强度集合：

$$\eta \in \{0.0, 0.5, 1.0, 1.5, 2.0\} \quad (32)$$

其中， $\eta = 0.0$ 对应理想无失配情形，其余取值对应逐渐增强的参数扰动水平。

图 6 展示了不同失配强度下各控制方法的误差演化过程，表 3 给出了相应的定量比较结果。




图 6: 节点 3 不同参数失配条件下各控制方法的同步误差演化过程

为了进一步考察所提方法在非最优牵制节点下的适应性，本文补充比较了节点 2 场景下 PPO 与传统线性反馈控制在不同参数失配条件下的同步性能。根据前述局部稳定性与可控性分析，节点 2 虽具有一定控制传播能力，但其同步流形局部稳定性弱于节点 3，因此属于一个更具挑战性的单输入控制场景。

由图 7 可见，在节点 2 场景下，PPO 与线性反馈控制之间呈现出显著性能差异。随着参数失配强度的增加，PPO 的平均同步误差始终保持在较低水平，而线性反馈控制在整个失配区间内均表现出明显更大的误差。特别

表 3: 节点 3 不同参数失配条件下的同步性能定量比较

Mismatch Scale(η)	MAE		Final L_1 Error	
	PPO	Linear	PPO	Linear
0.0	0.0212	0.0252	0.0125	0.0001
0.5	0.0192	0.0198	0.0308	0.0222
1.0	0.0226	0.0245	0.0459	0.0441
1.5	0.0261	0.0295	0.0611	0.0657
2.0	0.0299	0.0345	0.0763	0.0870

地，线性反馈在该节点上的最终同步误差始终维持在较高水平，表明其难以在节点 2 控制通道下实现有效同步。相比之下，PPO 仍能够维持较小的平均误差和稳态误差，说明所提深度强化学习方法在局部稳定性较弱的控制节点上具有更强的适应能力。




图 7: 节点 2 不同参数失配条件下各控制方法的同步误差演化过程

由于两种方法在该场景下的性能差异已经十分明显，正文中不再重复列出完整数值表格。

4.4 全局脉冲扰动下的瞬态恢复性能分析

脉冲抗扰实验是检验混沌动力学的一种方式 [13], 为进一步评估控制器在突发扰动作用下的瞬态恢复能力, 本文在测试过程中于第 200 步向系统三个状态分量同时注入等幅全局脉冲扰动, 即脉冲向量取为

$$p = [5, 5, 5]^T. \quad (33)$$

采用该设置的目的在于避免固定单节点受击所带来的控制通道不对称问题, 从而更公平地比较不同牵制节点下控制策略的抗扰恢复能力。图 8 给出了节点 2 与节点 3 场景下系统总同步误差在脉冲作用前后的演化过程。

从图 8 可以看出, 在节点 3 这一理论最优牵制节点下, PPO 与传统线性反馈控制均能够在脉冲注入后较快抑制误差增长, 并逐步恢复到较低误差水平。因此, 在最优控制通道下, 两种方法的瞬态恢复性能差异并不十分显著。这说明, 当控制输入作用于有利节点时, 传统线性反馈本身已能取得较好的抗扰恢复效果, 而所提 PPO 控制策略至少能够达到与其相当的恢复能力。

相比之下, 节点 2 场景下两种方法在全局脉冲扰动后的响应差异更为明显。由于节点 2 并非理论上的最优牵制节点, 传统线性反馈控制在该场景下表现出更高的误差峰值、更大的脉冲后平均误差, 并且在给定测试时长内难以重新进入严格误差阈值带。相比之下, PPO 仍能够在脉冲后有效抑制误差增长, 并保持较低的脉冲后平均误差水平。由此可见, 在非最优控制通道下, 深度强化学习策略相较固定结构的局部线性反馈具有更强的适应性与恢复能力。

考虑到节点 2 场景下线性反馈控制在预设阈值下始终无法恢复, 因此本文不再将恢复时间作为主要比较指标, 而采用脉冲后最大误差峰值 (Max Post-Pulse Error)、脉冲后平均误差 (Post-Pulse Mean Error) 以及控制能量 (Control Energy) 对不同方法进行定量评估。相关结果如表 4 所示。

表 4: 节点 2 场景下全局脉冲扰动恢复性能比较

Method	Max Post-Pulse Error	Post-Pulse Mean Error	Control Energy
PPO	14.9924	2.0650	19.4115
Linear Feedback	17.3844	5.5145	61.8433
Zero Input	14.9924	4.4985	0.00

由表 4 可见, 在节点 2 场景下, PPO 的脉冲后最大误差峰值为 14.9925,

低于线性反馈控制的 17.3845；同时，其脉冲后平均误差仅为 2.0651，显著小于线性反馈控制的 5.5145。此外，PPO 的控制能量为 19.4116，而线性反馈控制达到 61.8434，说明在当前全局脉冲扰动场景下，PPO 不仅恢复质量更好，而且总体控制代价更低。

综合来看，全局脉冲扰动实验进一步表明，不同牵制节点对控制器的瞬态恢复性能具有显著影响。在节点 3 这一最优牵制节点下，PPO 与传统线性反馈均能够实现较好的抗扰恢复；而在节点 2 这一更具挑战性的控制节点下，PPO 在误差峰值抑制、脉冲后平均误差以及控制能量等方面均表现出更明显的优势。该结果与前述局部稳定性与可控性分析总体一致，即节点 3 适合作为主实验中的最优控制节点，而节点 2 更能体现所提方法在困难控制场景下的适应性优势。




图 8: 节点 2 和 3 在相同脉冲下的恢复情况

4.5 部分可观测条件下的同步性能比较

在实际控制系统中，受传感器布置、通信带宽和测量精度等因素限制，控制器往往难以获得系统的完整状态信息。因此，在验证全观测条件下控制性能的基础上，进一步考察所提方法在观测受限条件下的同步能力具有重要意义。为此，本文在保持控制结构、训练流程和控制节点不变的前提下，比较节点 3 场景下全观测 PPO、四维部分观测 PPO 以及二维局部观测 PPO 的同步性能差异，从而分析观测信息受限对策略学习与闭环控制效果的影响，在混沌系统中，部分观测是现实且重要的问题 [14]。

在该实验中，节点 3 仍作为单输入牵制控制的作用节点。这一选择基于前述局部稳定性与可控性分析，以及不同 pinning 节点下的同步可达性实验结果。为保证比较的纯粹性，本文在部分可观测章节中固定节点 3，仅改变策略可利用的观测信息。具体而言，全观测策略可访问完整状态信息；四维部分观测策略利用如下观测量进行控制决策：

$$\mathcal{O}_{4D} = \{x_1, x_3, e_1, e_3\}, \quad (34)$$

而二维局部观测策略则仅利用

$$\mathcal{O}_{2D} = \{x_3, e_3\}. \quad (35)$$

图 9 给出了不同观测设定下节点 3 场景的同步误差演化过程，表 5 则从平均绝对误差（MAE）和终端时刻误差（Final L_1 Error）两个方面对结果进行了定量比较。

从图 9 可以看出，全观测 PPO 与四维部分观测 PPO 的误差演化曲线整体较为接近，二者均能够较快实现误差衰减，并在后期保持较低的同步误差水平。这说明，在节点 3 场景下，即使观测信息由全状态缩减为四维局部状态，所学策略仍能够提取足够的动力学特征，从而维持稳定有效的同步控制性能。

表 5 的定量结果进一步验证了这一现象。全观测 PPO 的 MAE 和 Final L_1 Error 分别为 0.0637 和 0.01248，而四维部分观测 PPO 对应结果为 0.0632 和 0.0096，二者处于非常接近的量级。需要指出的是，尽管当前实验结果中四维部分观测设定在数值上略优于全观测设定，但考虑到两者差异较小，更合理的解释应是：在节点 3 场景下，四维部分观测 PPO 与全观测 PPO 的同步性能基本相当，而不宜将其简单解读为部分观测优于全观测。

相比之下，当观测空间进一步压缩为二维局部观测 $\{x_3, e_3\}$ 时，系统性能出现了明显退化。由表 5 可见，二维局部观测 PPO 的 MAE 提高至 0.1111，Final L_1 Error 也增大至 0.0610，明显劣于全观测和四维部分观测结果。这说明，当可利用的观测信息进一步减少时，策略对系统动力学特征的识别能力受到显著限制，从而增加了同步控制任务的学习难度，并导致最终同步精度下降。

综合来看，节点 3 场景下的部分可观测实验表明，所提 PPO 控制策略对观测信息缺失具有较强适应性。在四维部分观测设定下，系统仍能够实现与全观测情形基本接近的同步性能；而当观测进一步压缩至二维局部观测时，平均误差与最终误差均明显增大，说明过度减少观测信息会显著增加策略学习与同步控制的难度。该结果表明，所提方法并不严格依赖系统全状态信息，但其性能仍受可观测信息丰富程度的影响。




图 9: 节点 3 场景下，不同观测配置下 L_1 误差的比较。实线表示 3 次独立运行的平均值，阴影区域表示通过自举法计算的 95% 置信区间。

5 结论

本文针对连续时间 Hopfield 型混沌神经网络的主从同步控制问题，研究了基于深度强化学习的单输入牵制控制方法。首先，在驱动-响应框架下

表 5: 不同观测设定下节点 3 场景的同步性能比较

Observation Setting	MAE	Final L_1 Error
Full Observation	0.0637	0.01248
4D Partial Observation ($\{x_1, x_3, e_1, e_3\}$)	0.0632	0.0096
2D Local Observation ($\{x_3, e_3\}$)	0.1111	0.0610

构建了同步误差系统，并结合条件李雅普诺夫指数、局部最优控制代价和控制传播能力指标，对不同牵制节点的局部可控性进行了综合分析。理论结果表明，节点 3 在局部稳定性和控制可达性方面均优于其余节点，为后续控制节点选择提供了依据。

在控制方法方面，本文采用基于 PPO 的深度强化学习策略实现单输入同步控制，并与传统线性反馈控制进行了比较。实验结果表明，在理论最优牵制节点下，PPO 能够实现与传统方法相当的同步性能；在参数失配条件下，所提方法能够保持较低的同步误差；在全局脉冲扰动作用下，PPO 在非最优控制节点场景中表现出更好的误差峰值抑制能力和更低的脉冲后平均误差，说明其在更具挑战性的控制通道下具有较强的适应性。

进一步地，本文还考察了观测受限条件下的同步性能。结果表明，在四维部分观测设定下，节点 3 场景的同步性能与全观测情形基本接近，说明所提方法对一定程度的观测信息缺失具有较强适应性；而当观测进一步缩减为二维局部观测时，系统性能出现明显退化，且仅节点 3 能够稳定训练成功，这说明在极低观测维度条件下，牵制节点选择对策略可学习性的影响更加显著。

综上所述，本文表明，基于 PPO 的深度强化学习方法能够为连续时间 Hopfield 型混沌神经网络的单输入同步控制提供一种有效方案，并在参数失配、全局脉冲扰动和部分可观测等非理想场景下表现出较好的鲁棒性与适应性。未来工作可进一步考虑更大规模神经网络、多牵制节点协同控制以及时滞、噪声等更复杂工况下的同步控制问题。

参考文献

- [1] John J Hopfield. Neurons with graded response have collective computational properties like those of two-state neurons. *Proceedings of the*

- national academy of sciences*, 81(10):3088–3092, 1984.
- [2] Juan Li, Feng Liu, Zhi-Hong Guan, and Tao Li. A new chaotic hopfield neural network and its synthesis via parameter switchings. *Neurocomputing*, 117:33–39, 2013.
 - [3] Emad E Mahmoud, Lone Seth Jahanzaib, Pushali Trikha, and Omar A Almaghrabi. Analysis and control of the fractional chaotic hopfield neural network. *Advances in Difference Equations*, 2021(1):126, 2021.
 - [4] Stefano Boccaletti, Jürgen Kurths, Grigory Osipov, DL Valladares, and CS Zhou. The synchronization of chaotic systems. *Physics reports*, 366(1-2):1–101, 2002.
 - [5] Jean-Jacques E Slotine, Weiping Li, et al. *Applied nonlinear control*. Prentice hall Englewood Cliffs, NJ, 1991.
 - [6] Louis M Pecora and Thomas L Carroll. Master stability functions for synchronized coupled systems. *Physical review letters*, 80(10):2109, 1998.
 - [7] Jan Willems. Least squares stationary optimal control and the algebraic riccati equation. *IEEE Transactions on automatic control*, 16(6):621–634, 2003.
 - [8] Thomas Kailath. *Linear systems*, volume 156. Prentice-Hall Englewood Cliffs, NJ, 1980.
 - [9] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
 - [10] Jan Kobiolka, Jens Habermann, and Marius E Yamakou. Reduced-order adaptive synchronization in a chaotic neural network with parameter mismatch: a dynamical system versus machine learning approach. *Nonlinear Dynamics*, 113(10):10989–11008, 2025.
 - [11] MT Yassen. Controlling chaos and synchronization for new chaotic system using linear feedback control. *Chaos, Solitons & Fractals*, 26(3):913–920, 2005.

- [12] Wei Zhang, Junjian Huang, and Pengcheng Wei. Weak synchronization of chaotic neural networks with parameter mismatch via periodically intermittent control. *Applied Mathematical Modelling*, 35(2):612–620, 2011.
- [13] Zhengran Cao, Chuandong Li, and Man-Fai Leung. The synchronisation problem of chaotic neural networks based on saturation impulsive control and intermittent control. *Mathematics*, 12(1):151, 2024.
- [14] Max Weissenbacher, Anastasia Borovykh, and Georgios Rigas. Reinforcement learning of chaotic systems control in partially observable environments. *Flow, Turbulence and Combustion*, 115(3):1357–1378, 2025.